

# 评测体系与效果验证

100 条 Benchmark Query • 10 个端到端任务 • 全维度指标体系

## 核心指标一览

|                |          |                      |           |
|----------------|----------|----------------------|-----------|
| Top-1 Accuracy | Recall@3 | MRR                  | Agent 成功率 |
| 86.0%          | 94.0%    | 0.887                | 100.0%    |
| 86/100         | 94/100   | Mean Reciprocal Rank | 10/10 任务  |

表 1: ReActLab Benchmark 核心指标汇总

## RAG 检索评估 (100 条 Benchmark Query)

| 指标             | 数值             | 说明                                 |
|----------------|----------------|------------------------------------|
| Top-1 Accuracy | 86.0% (86/100) | 正确答案出现在检索结果第 1 位的比例                |
| Recall@3       | 94.0% (94/100) | 正确答案出现在检索结果前 3 位的比例                |
| MRR            | 0.8867         | Mean Reciprocal Rank — 正确答案排名的倒数均值 |
| 测试集规模          | 100 条 Query    | 覆盖 CPU / 内存 / 磁盘 / 服务故障 4 类场景      |

## Agent 端到端评测 (10 个诊断任务)

| 指标           | 数值                          | 说明                                      |
|--------------|-----------------------------|-----------------------------------------|
| 任务成功率        | 100.0% (10/10)              | Agent 完整执行 Plan→Execute→Report，输出有效诊断报告 |
| Runtime 框架   | Plan-Execute-Replan         | LangGraph 构建的多节点状态图                     |
| 工具数量         | 7 个                         | retrieve_knowledge + 4 MCP 工具 + 2 时间工具  |
| MCP 重试恢复率    | 无重试: 1/4 → 有重试: 3/4 (+50pp) | 指数退避策略显著提升工具调用可靠性                       |
| API 延迟 (p50) | 218.0ms                     | FastAPI 健康检查端点 p50 响应时间                 |

Demo: Agent 实时对话效果




图 3: ReActLab Web 端 Agent 流式对话 — 任务诊断与报告生成